Asistente RAG de permanencia estudiantil: ingesta, vectorización e indexación semántica en Qdrant Cloud

Bonny Darhyll Brayan Galindo Santos · Camilo José Rodríguez Ayubi · Andrés Alberto López Herrera
Docente: Hamilton Rivera Flor · Noviembre de 2026 · Pilar 2: Educación

OBJETIVO GENERAL

Diseñar e implementar la arquitectura cloud de ingesta, *chunking*, embeddings y almacenamiento semántico en una base vectorial gestionada, integrando un dataset estructurado de deserción con normativa colombiana de permanencia y bienestar.

SITUACIÓN PROBLEMA

Cerca de la mitad de quienes ingresan a la universidad en Colombia no terminan (MEN, 2015). Las reglas que podrían ayudarles están dispersas en cientos de páginas.

> *¿Cómo indexar y recuperar semánticamente información especializada en la nube con alta precisión, costo cero y baja latencia?*

LO QUE HACE EL SISTEMA

32,1 %
de deserción en la cohorte UCI (4.424 estudiantes)

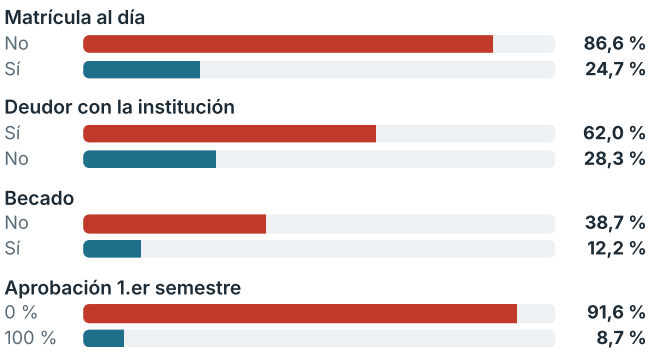
Responde preguntas de estudiantes con el **artículo exacto** del reglamento, la **estrategia** del MEN y la **evidencia cuantitativa** del dataset, citando documento y página.

CORPUS DOCUMENTAL + DATASET BASE

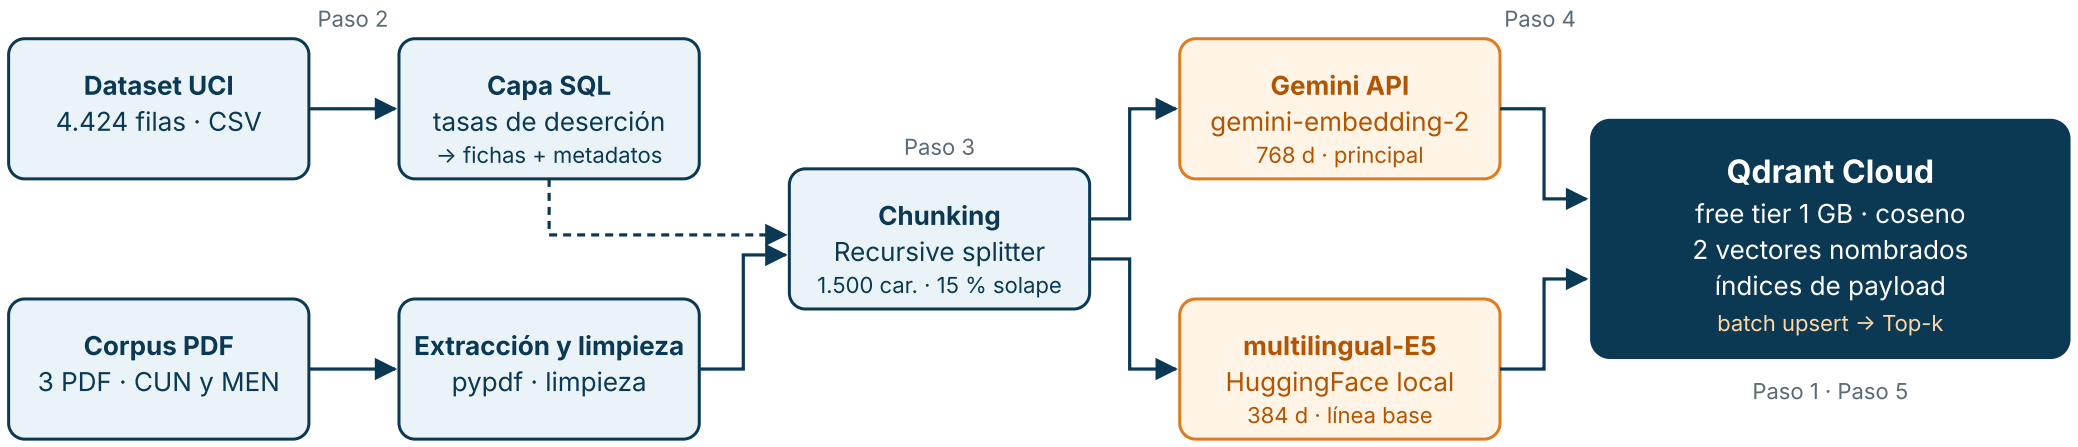
FUENTE	TIPO	APORTE	
Reglamento Estudiantil CUN Acuerdo 002 de 2011	reglamento	Matrícula, retiros, reintegros, transferencias, evaluación, grados	45 págs. 113 chunks
Guía de permanencia y graduación MEN, 2015	guía	Modelo de gestión, ruta de 4 pasos, caja de 37 herramientas	227 págs. 383 chunks
Lineamientos de política de bienestar MEN, 2016	política	Principios, dimensiones y componentes del bienestar	55 págs. 104 chunks
UCI Predict Students' Dropout Realinho et al., 2021	dataset	36 variables · capa SQL → fichas analíticas y metadatos por factor de riesgo	4.424 filas 10 chunks

EVIDENCIA DEL DATASET (SQL)

% de deserción por grupo · se adjunta como metadato a los fragmentos del mismo factor



ARQUITECTURA CLOUD DE DATOS



STACK TECNOLÓGICO (CAPA GRATUITA)

Qdrant Cloud
Free tier 1 GB · métrica coseno · vectores `gemini` y `e5` · índices de payload

Gemini gemini-embedding-2
768 d (Matryoshka) · consulta `task: search result` ≡ RETRIEVAL_QUERY

multilingual-E5-small
HuggingFace · 384 d · prefijos `query:`/`passage:`

LangChain splitter + pypdf
Corte jerárquico capítulo → artículo → párrafo → oración

SQLite
Agregaciones SQL del dataset (migrable a Supabase)

Colab + GitHub
Notebook reproducible · credenciales en `.env`

CHUNKING: DECISIÓN CON DATOS

- **1.500 caracteres** (~375 tokens) con **225** de solapamiento (15 %).
- Ganó el experimento: conserva completa cada estrategia de la guía del MEN (varios párrafos) y sigue por debajo del límite de 512 tokens de E5.
- Separadores: `CAPÍTULO · ARTÍCULO · ¶ · línea · oración`.
- Experimento previo a la nube (E5 local, 14 consultas): 500: MRR 0,943 · 1000: MRR 0,946 · 1500: MRR 0,964.
- IDs UUID v5 deterministas → re-cargas idempotentes; lotes de 64 con `wait=True`.

CONSULTAS SEMÁNTICAS (TOP-1)

"¿Qué pasa si pierdo la misma asignatura por tercera vez?"
0,798 Reglamento CUN, p. 26 — *Art. 58. Pérdida reiterada de asignaturas: quien deba cursar una asignatura por tercera vez solo podrá hacerlo con autorización del Comité de Programa.*

"¿Qué estrategias recomienda el Ministerio para apoyar a estudiantes con dificultades económicas?"
0,766 Guía MEN 2015, p. 167 — *Componente 7, Gestión de recursos: una unidad con personal especializado que asesore y apoye la financiación del estudiante.*

"¿Los estudiantes con deudas con la institución abandonan más sus estudios?"
0,832 Ficha dataset UCI — *Ficha del factor deudor: 62,0 % de deserción entre deudores frente a 28,3 % entre quienes no tienen deudas (n = 4.424).*

VALIDACIÓN DE LA RECUPERACIÓN

	GEMINI · 768 D	E5 · 384 D
Hit@1	**1,00**	0,93
Hit@3	**1,00**	1,00
MRR	**1,00**	0,96
Coseno Top-1 medio	0,805	0,891
Coseno fuera de dominio	0,547	0,767
Latencia Qdrant (mediana)	221 ms	220 ms

14 consultas de validación + 2 de control fuera de dominio. Umbral de relevancia calibrado: Gemini ≥ 0,645. El coseno no es comparable entre modelos; se comparan rankings.

ENLACES

Repositorio
https://github.com/BonnyGalindo77/aca1-rag-educacion-qdrant

QR

Video de sustentación
https://youtu.be/ENLACE-DEL-VIDEO

REFERENCIAS (APA 7)

Corporación Unificada Nacional de Educación Superior. (2011). *Reglamento estudiantil* (Acuerdo 002 de 2011). https://cdigital.cun.edu.co

Google. (2026). *Embeddings* [Documentación de la API de Gemini]. https://ai.google.dev/gemini-api/docs/embeddings

Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., ... Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. *Advances in Neural Information Processing Systems, 33*, 9459–9474.

Ministerio de Educación Nacional. (2015). *Guía para la implementación del modelo de gestión de permanencia y graduación estudiantil en instituciones de educación superior*.

Ministerio de Educación Nacional. (2016). *Lineamientos de política de bienestar para instituciones de educación superior*.

Qdrant Solutions GmbH. (2026). *Qdrant documentation*. https://qdrant.tech/documentation/

Realinho, V., Vieira Martins, M., Machado, J., & Baptista, L. (2021). *Predict students' dropout and academic success* [Conjunto de datos]. UCI Machine Learning Repository. https://doi.org/10.24432/C5MC89

Wang, L., Yang, N., Huang, X., Yang, L., Majumder, R., & Wei, F. (2024). *Multilingual E5 text embeddings: A technical report* (arXiv:2402.05672).